DỰ ÁN

HỆ THỐNG PHÁT HIỆN ĐÁM CHÁY VÀ KHÓI THỜI GIAN THỰC SỬ DỤNG MÔ HÌNH YOLOv8s

Fire and Smoke Real-Time Detection System
Using YOLOv8s Deep Learning Model

Lĩnh vực	Thị giác máy tính — Phát hiện đối tượng (Object Detection)
Công nghệ	YOLOv8s (Ultralytics), PyTorch 2.5.1, CUDA 12.1
Phần cứng	NVIDIA GeForce RTX 3050 Laptop GPU (4GB VRAM)
Ngôn ngữ	Python 3.11.4
Mô hình	YOLOv8s — 11.12M params, 28.4 GFLOPs, 72 layers

MỤC LỤC

1. Lời mở đầu
2. Tổng quan
3. Giới thiệu chung
4. Cơ sở lý thuyết
5. Phương pháp
6. Thực nghiệm và kết quả
7. Kết luận
8. Hướng phát triển
9. Tài liệu tham khảo

CHƯƠNG 1: LỜI MỞ ĐẦU

Cháy nổ là một trong những hiểm họa nghiêm trọng nhất đối với con người, tài sản và môi trường. Theo thống kê của Cục Cảnh sát Phòng cháy, Chữa cháy và Cứu nạn, Cứu hộ (Bộ Công an Việt Nam), mỗi năm cả nước ghi nhận hàng ngàn vụ cháy gây thiệt hại lớn về người và tài sản. Trên phạm vi toàn cầu, Tổ chức Phòng cháy Quốc tế (NFPA — National Fire Protection Association) ước tính thiệt hại do hỏa hoạn lên tới hàng chục tỷ USD mỗi năm. Điểm chung của phần lớn các vụ cháy lớn là sự chậm trễ trong phát hiện ban đầu — khi ngọn lửa hoặc cột khói còn nhỏ và có thể kiểm soát được.

Các hệ thống phát hiện cháy truyền thống (cảm biến nhiệt, cảm biến khói) tồn tại nhiều hạn chế:

- Phạm vi giám sát hẹp: Mỗi cảm biến chỉ bao phủ một vùng không gian nhỏ.
- Tốc độ phản hồi chậm: Cảm biến nhiệt cần nhiệt độ tăng đến ngưỡng mới kích hoạt.
- Tỉ lệ báo động giả cao: Khói từ nấu ăn, bụi bẩn có thể kích hoạt sai lệch.
- Không cung cấp thông tin trực quan: Chỉ đưa ra tín hiệu nhị phân (có/không).

Sự phát triển của Trí tuệ nhân tạo (AI) và Thị giác máy tính (Computer Vision) đã mở ra hướng tiếp cận mới: sử dụng camera giám sát kết hợp mô hình học sâu (deep learning) để phát hiện đám cháy và khói từ hình ảnh/video theo thời gian thực.

Dự án này tập trung xây dựng và đánh giá hệ thống phát hiện đám cháy và khói thời gian thực sử dụng mô hình YOLOv8s (You Only Look Once version 8 — Small) — một trong những kiến trúc phát hiện đối tượng hiện đại nhất, với ưu thế vượt trội về cân bằng giữa tốc độ và độ chính xác.

CHƯƠNG 2: TỔNG QUAN

2.1. Bối cảnh và Tính cấp thiết

Phát hiện cháy sớm (early fire detection) là yếu tố then chốt trong việc giảm thiểu thiệt hại. Nghiên cứu cho thấy nếu đám cháy được phát hiện trong 3 phút đầu tiên, khả năng dập tắt thành công lên tới 90%. Tuy nhiên, sau 5-10 phút, đám cháy có thể lan rộng gấp nhiều lần và trở nên khó kiểm soát.

Hệ thống camera giám sát (CCTV) đã được lắp đặt phổ biến nhưng chỉ ghi hình thụ động. Việc tích hợp AI cho phép tự động hóa giám sát, biến camera thành bộ phát hiện thông minh chủ động.

2.2. Mục tiêu của dự án

1. Xây dựng mô hình phát hiện hai lớp đối tượng: Ngọn lửa (Fire) và Khói (Smoke).
2. Đạt độ chính xác mAP@0.5 ≥ 75% trên tập kiểm thử độc lập.
3. Đảm bảo tốc độ xử lý thời gian thực ≥ 30 FPS trên GPU RTX 3050.
4. Đánh giá toàn diện thông qua Precision, Recall, mAP, Confusion Matrix, và các đường cong P-R, F1.
5. Đề xuất giải pháp tối ưu hóa và hướng triển khai thực tế.

CHƯƠNG 3: GIỚI THIỆU CHUNG

3.1. Bài toán phát hiện đối tượng (Object Detection)

Phát hiện đối tượng là bài toán cốt lõi trong Thị giác máy tính, xác định đồng thời vị trí (localization) và phân loại (classification) các đối tượng trong ảnh. Kết quả gồm: Bounding box (x, y, w, h), Class label, và Confidence score.

3.2. Phương pháp hai giai đoạn vs. một giai đoạn

Two-Stage Detectors (R-CNN, Faster R-CNN): Sinh vùng ứng viên → Phân loại. Chính xác nhưng chậm.

One-Stage Detectors (YOLO, SSD, RetinaNet): Dự đoán đồng thời trong một lần forward pass. Nhanh, phù hợp real-time.

3.3. Lịch sử phát triển dòng YOLO

Phiên bản	Năm	Đóng góp chính
YOLOv1	2016	Mô hình one-stage đầu tiên, chia ảnh thành lưới S×S
YOLOv2	2017	Batch Normalization, anchor boxes, multi-scale training
YOLOv3	2018	Darknet-53, FPN, dự đoán đa tỉ lệ
YOLOv4	2020	CSPDarknet53, Mosaic augmentation, BoF/BoS
YOLOv5	2020	PyTorch reimplementation, Auto-anchor, dễ triển khai
YOLOv7	2022	E-ELAN, compound scaling, auxiliary head
YOLOv8	2023	C2f module, Decoupled Head, Anchor-free, Task-Aligned Assigner

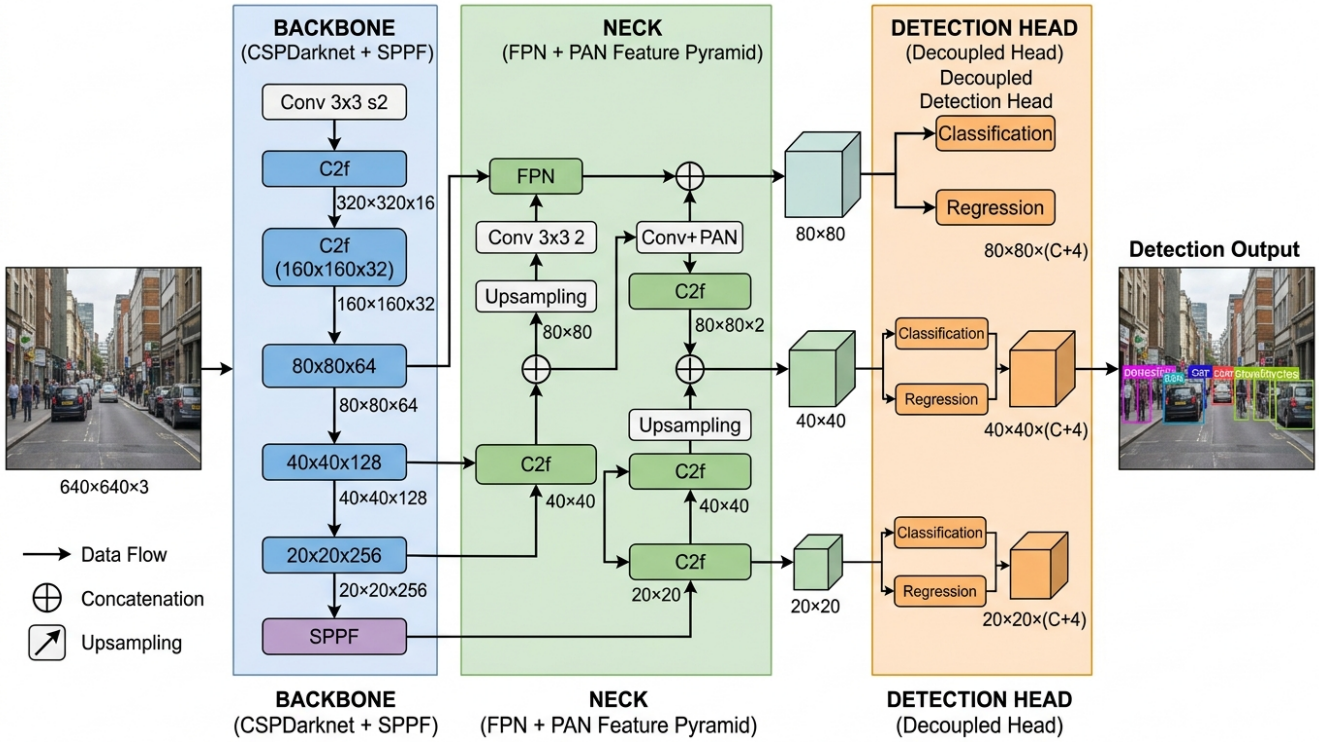
3.4. Lý do chọn YOLOv8s

- Cân bằng tốc độ - độ chính xác: 11.12M tham số, nằm giữa Nano và Large.
- Kiến trúc hiện đại: Anchor-free, Decoupled Head, C2f module.
- Hệ sinh thái hoàn chỉnh: Ultralytics API hỗ trợ train/val/predict/export.
- Triển khai đa nền tảng: Xuất ONNX, TensorRT, CoreML, TFLite.
- Phù hợp phần cứng: Hiệu quả trên GPU phổ thông RTX 3050 (4GB VRAM).

CHƯƠNG 4: CƠ SỞ LÝ THUYẾT

4.1. Kiến trúc YOLOv8

YOLOv8 gồm 3 thành phần chính: Backbone (CSPDarknet + C2f + SPPF), Neck (FPN + PAN), và Head (Decoupled Detection Head, Anchor-Free).



Hình 1: Kiến trúc tổng quan mô hình YOLOv8s — Backbone, Neck, Detection Head

4.1.1. Backbone — CSPDarknet với C2f Module

Backbone trích xuất đặc trưng từ ảnh đầu vào. Module C2f (cải tiến từ C3 trong YOLOv5) kết hợp ý tưởng ELAN: chia đặc trưng thành hai nhánh, nhánh thứ hai đi qua n bottleneck blocks, concatenate tất cả đầu ra trung gian, rồi trộn bằng convolution 1×1.

SPPF (Spatial Pyramid Pooling — Fast): Nằm ở cuối backbone, thực hiện pooling đa tỉ lệ bằng 3 lớp MaxPool 5×5 nối tiếp để tổng hợp ngữ cảnh toàn cục.

4.1.2. Neck — FPN + PAN

FPN: Truyền thông tin ngữ nghĩa top-down. PAN: Truyền thông tin localization bottom-up. Kết quả: 3 bản đồ đặc trưng: P3 (80×80) — đối tượng nhỏ, P4 (40×40) — trung bình, P5 (20×20) — lớn.

4.1.3. Head — Decoupled Head (Anchor-Free)

YOLOv8 tách riêng nhánh Classification và Regression (Decoupled Head). Loại bỏ hoàn toàn anchor boxes, dự đoán trực tiếp bounding box tại mỗi vị trí grid. Sử dụng Distribution Focal Loss (DFL) để mô hình hóa từng cạnh hộp như phân phối xác suất rời rạc.

4.2. Hàm mất mát (Loss Functions)

L_total = λ_box · L_box + λ_cls · L_cls + λ_dfl · L_dfl

- Box Loss (CIoU): L_CIoU = 1 - IoU + ρ²(b,b_gt)/c² + αv — Xét khoảng cách tâm, tỉ lệ khung hình.
- Classification Loss: Binary Cross-Entropy với Sigmoid cho phân loại đa nhãn.
- DFL: Distribution Focal Loss cho hồi quy bounding box chính xác hơn.

4.3. Các chỉ số đánh giá

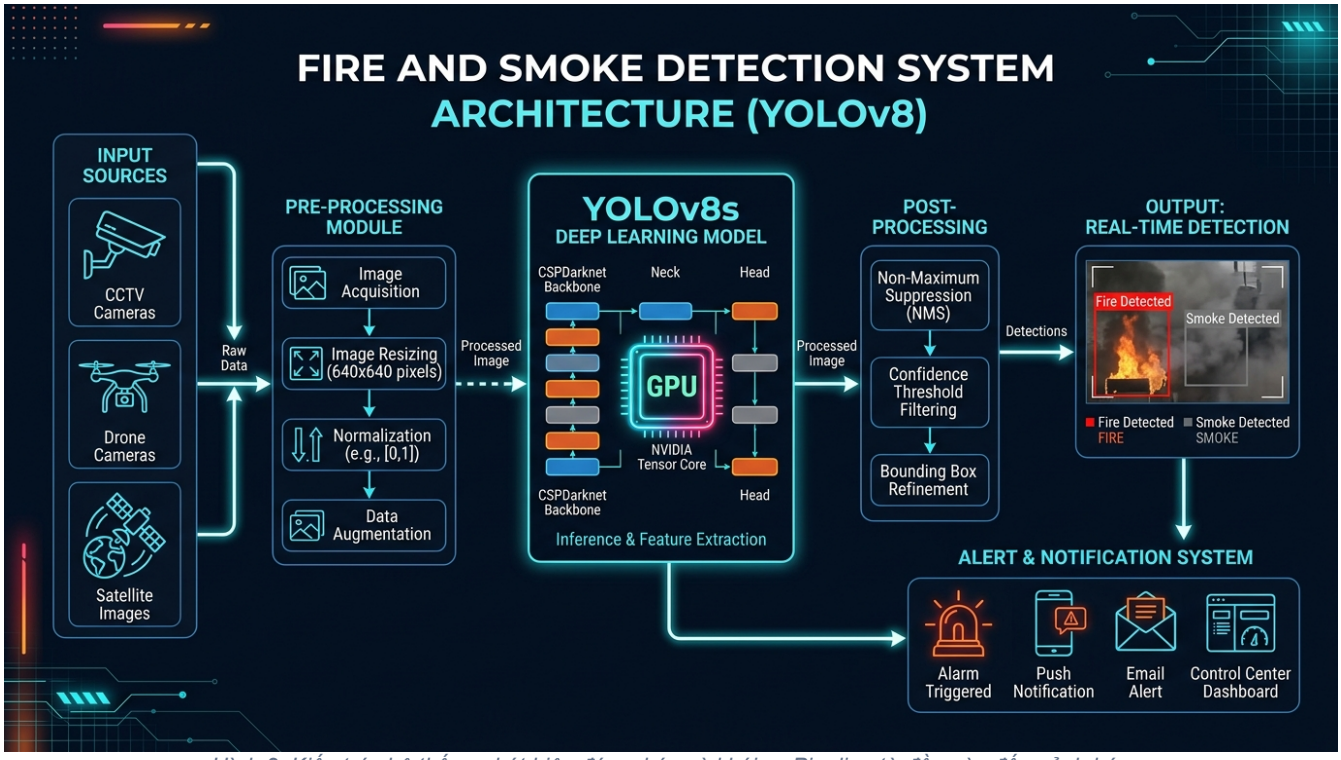
Chỉ số	Công thức	Ý nghĩa
Precision	TP / (TP + FP)	Tỉ lệ dự đoán đúng — ít báo động giả
Recall	TP / (TP + FN)	Tỉ lệ phát hiện đúng — ít bỏ sót
F1-Score	2×P×R / (P+R)	Trung bình điều hòa Precision & Recall
mAP@0.5	Mean AP tại IoU=0.5	Chỉ số tổng hợp chính
mAP@0.5:0.95	Mean AP, IoU 0.5→0.95	Chỉ số nghiêm ngặt hơn
IoU	|A∩B| / |A□B|	Mức trùng khớp predicted vs ground truth

4.4. Kỹ thuật tăng cường dữ liệu (Data Augmentation)

Kỹ thuật	Mô tả	Tham số
Mosaic	Ghép 4 ảnh thành 1	mosaic=1.0
HSV Augmentation	Biến đổi Hue/Saturation/Value	h=0.015, s=0.7, v=0.4
Horizontal Flip	Lật ngang ngẫu nhiên	fliplr=0.5
Scale / Translate	Co giãn và dịch chuyển	scale=0.5, translate=0.1
Erasing	Xóa ngẫu nhiên vùng ảnh	erasing=0.4
RandAugment	Auto-augmentation policy	auto_augment=randaugment

CHƯƠNG 5: PHƯƠNG PHÁP

5.1. Kiến trúc hệ thống tổng quan



Hình 2: Kiến trúc hệ thống phát hiện đám cháy và khói — Pipeline từ đầu vào đến cảnh báo

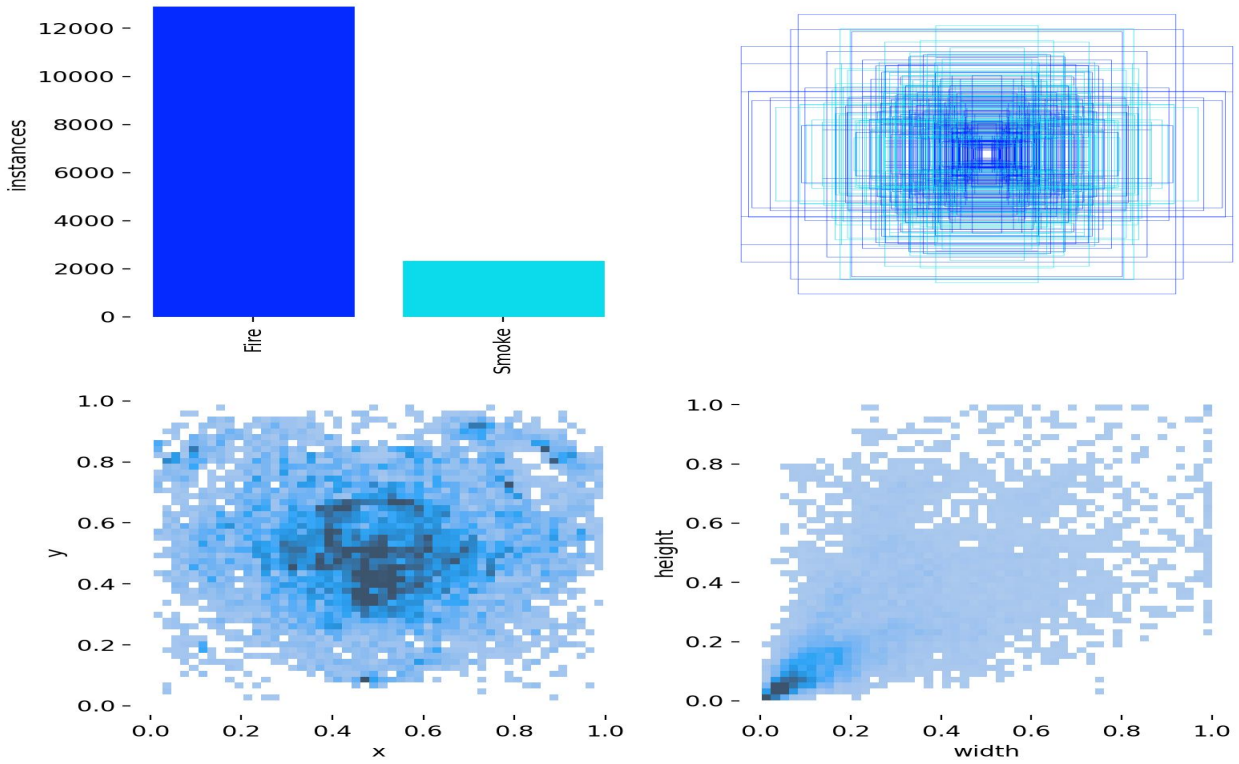
Hệ thống gồm 5 giai đoạn: (1) Thu thập từ camera CCTV/drone, (2) Tiền xử lý resize 640×640, (3) Suy luận YOLOv8s trên GPU, (4) Hậu xử lý NMS, (5) Hiển thị & cảnh báo.

5.2. Tập dữ liệu

Tập dữ liệu	Số lượng ảnh	Mục đích
Training (Huấn luyện)	~7,000 ảnh	Huấn luyện mô hình
Validation (Xác thực)	2,000 ảnh	Theo dõi hiệu năng & điều chỉnh
Test (Kiểm thử)	1,000 ảnh	Đánh giá cuối cùng, độc lập

Dữ liệu đa dạng: cháy trong nhà, cháy rừng, cháy phương tiện, khói trắng/đen, ban ngày/đêm, và các trường hợp gây nhiễu (hoàng hôn, đèn LED, sương mù).

5.2.1. Phân bố nhãn trong tập dữ liệu



Hình 3: Phân bố nhãn — mất cân bằng giữa Fire và Smoke, phân bố vị trí/kích thước bounding box

5.3. Cấu hình huấn luyện

Siêu tham số	Giá trị	Siêu tham số	Giá trị
Mô hình cơ sở	yolov8s.pt (COCO)	Epochs	50
Batch size	16	Image size	640 × 640
Optimizer	Auto (SGD)	Learning rate	lr0=0.01, lrf=0.01
Momentum	0.937	Weight decay	0.0005
Warmup epochs	3.0	AMP	True (Mixed Precision)
IoU threshold	0.7	Close mosaic	10 (cuối)

CHƯƠNG 6: THỰC NGHIỆM VÀ KẾT QUẢ

6.1. Thông tin mô hình

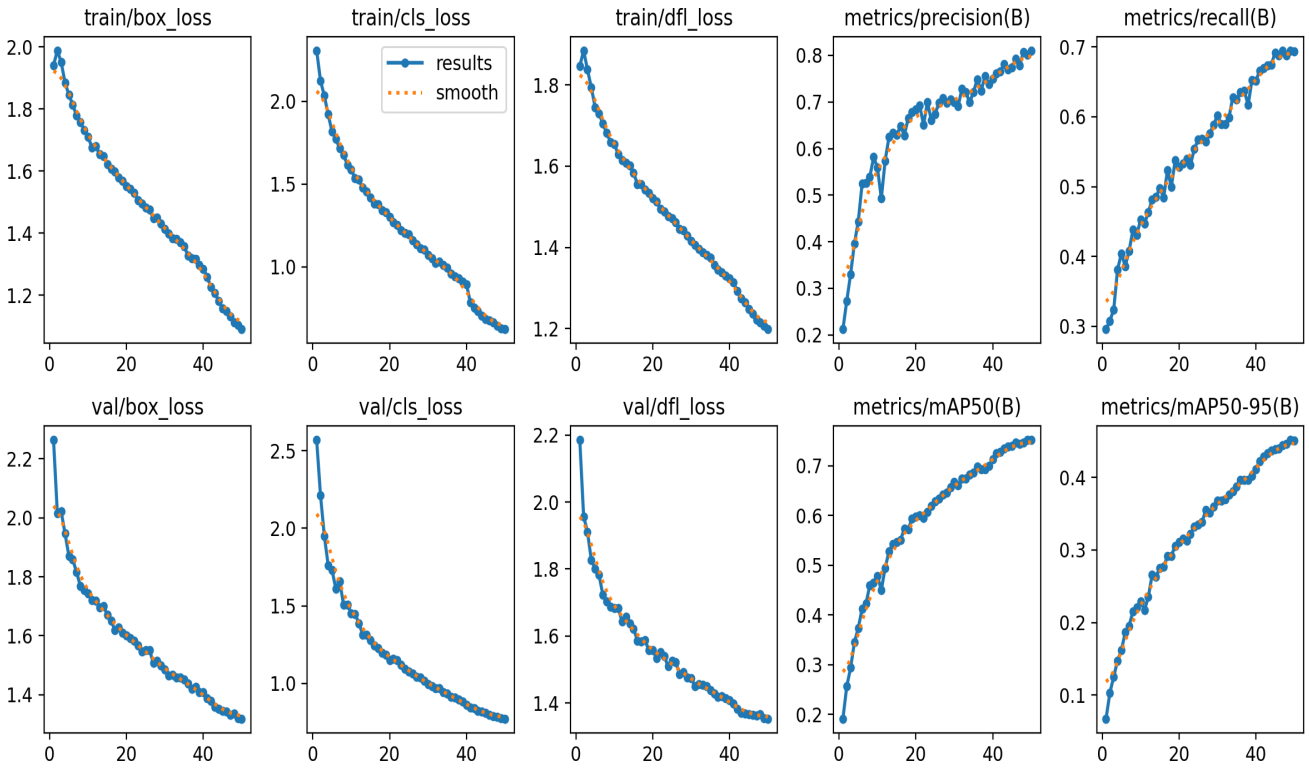
Hạng mục	Chi tiết	Hạng mục	Chi tiết
Kiến trúc	YOLOv8s (72 layers)	Tổng tham số	11.12 triệu
Độ phức tạp	28.4 GFLOPs	Thời gian train	~3.65 giờ (13,154s)

6.1.1. Minh họa batch huấn luyện



Hình 4: Batch huấn luyện với Mosaic augmentation và ground truth bounding box

6.1.2. Biểu đồ quá trình huấn luyện



Hình 5: Đường cong huấn luyện qua 50 epochs — Box/Cls/DFL Loss, Precision, Recall, mAP

Phân tích: Tất cả hàm loss giảm đều đặn, Precision/Recall tăng và ổn định từ epoch 20. Khoảng cách train-val loss nhỏ → không có dấu hiệu overfitting.

6.2. Kết quả đánh giá định lượng

A. Kết quả trên tập Kiểm thử độc lập (Test Set — 1,000 ảnh)

Phân loại	Số nhãn	Precision	Recall	mAP@0.5	mAP@0.5:0.95
Toàn bộ (All)	2,177	78.8%	73.9%	77.4%	47.0%
Lửa (Fire)	1,839	86.1%	81.1%	87.1%	56.1%
Khói (Smoke)	338	71.5%	66.7%	67.7%	37.8%

• mAP@0.75 trên tập Test: 50.6%

B. Kết quả trên tập Xác thực (Validation Set — 2,000 ảnh)

Phân loại	Số nhãn	Precision	Recall	mAP@0.5	mAP@0.5:0.95
Toàn bộ (All)	4,312	80.1%	69.5%	75.1%	45.1%
Lửa (Fire)	3,627	87.5%	79.2%	85.5%	55.0%
Khói (Smoke)	685	72.7%	59.9%	64.8%	35.3%

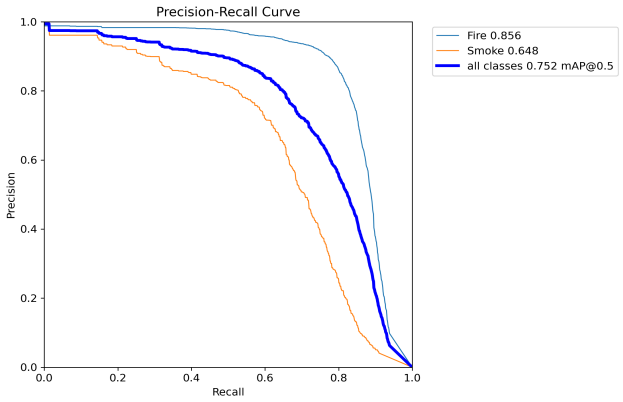
• mAP@0.75 trên tập Val: 48.0%

C. Tốc độ suy luận (Inference Speed — GPU RTX 3050)

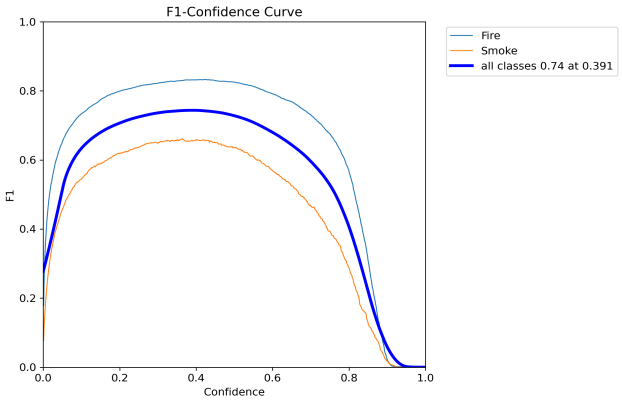
Giai đoạn	Thời gian	Tốc độ
Tiền xử lý (Preprocess)	0.3 ms/ảnh	—
Suy luận (Inference)	10.7 ms/ảnh	~93.5 FPS
Hậu xử lý NMS	1.0 ms/ảnh	—
Tổng (End-to-End)	~12.0 ms/ảnh	~83 FPS

→ Tốc độ 83 FPS vượt xa yêu cầu camera giám sát (25-30 FPS), đáp ứng giám sát đa luồng (multi-stream).

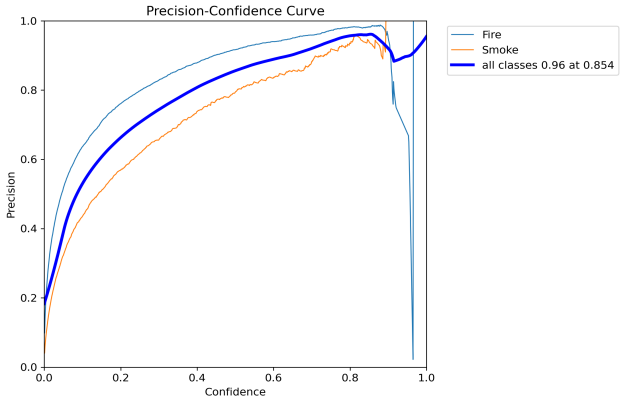
6.3. Đường cong đánh giá hiệu năng



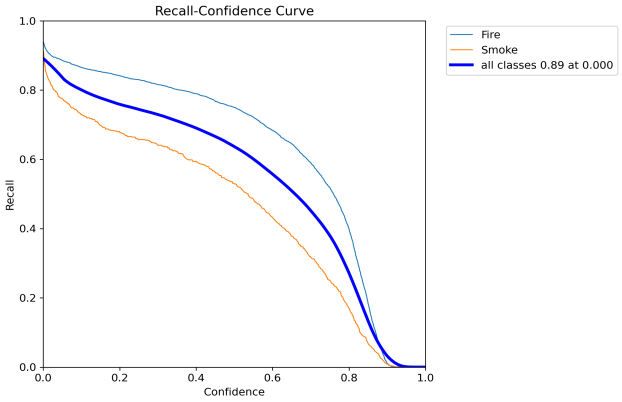
Hình 6: Đường cong Precision-Recall



Hình 7: Đường cong F1-Score theo Confidence



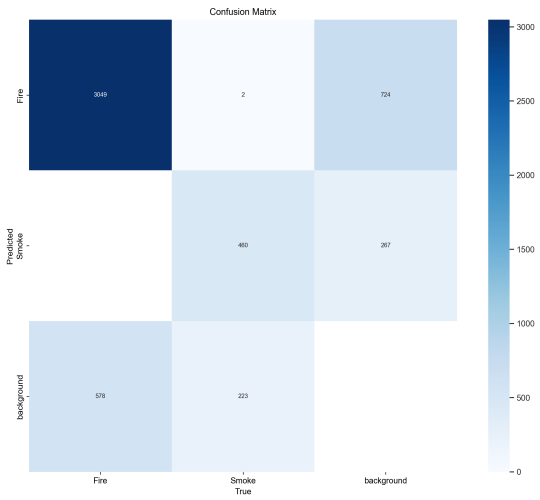
Hình 8: Đường cong Precision theo Confidence



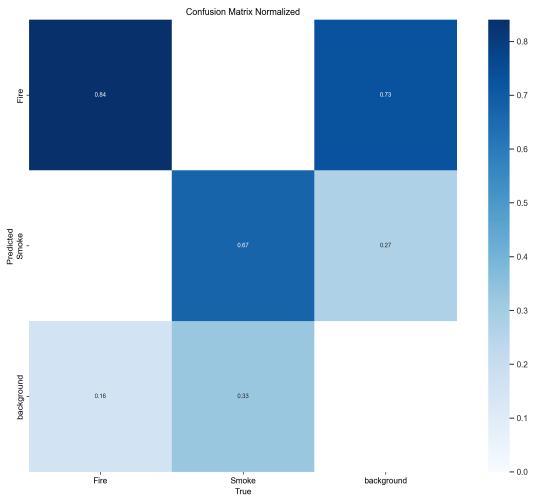
Hình 9: Đường cong Recall theo Confidence

Phân tích: Lớp Fire có đường PR cao và rộng (AP=87.1%). Đường F1 đạt đỉnh ở conf ≈ 0.3-0.4 — ngưỡng tối ưu cho cân bằng phát hiện sớm vs. báo động giả.

6.4. Ma trận nhầm lẫn (Confusion Matrix)



Hình 10: Ma trận nhầm lẫn (raw)



Hình 11: Ma trận nhầm lẫn chuẩn hóa

Phân tích: Fire có tỉ lệ phân loại đúng cao, ít nhầm lẫn. Smoke có tỉ lệ FN cao hơn (khói loãng → Background). Nhầm lẫn Fire↔Smoke tương đối thấp.

6.5. Kết quả trực quan — So sánh Ground Truth vs. Prediction



Hình 12: Ground Truth (nhãn thật)



Hình 13: Prediction (YOLOv8s dự đoán)

Mô hình phát hiện chính xác vị trí và kích thước ngọn lửa. Confidence score thường 0.5-0.9. Một số khói loãng/khói xa bị bỏ sót hoặc confidence thấp.

6.6. Phân tích chuyên sâu

Điểm mạnh nổi bật:

- Tổng quát hóa xuất sắc: Test mAP@0.5 (77.4%) > Val mAP@0.5 (75.1%) → không overfitting.
- Fire detection vượt trội: P=86.1%, R=81.1%, mAP@0.5=87.1% — phát hiện ngọn lửa chính xác.
- Tốc độ 83 FPS: Gấp ~3 lần yêu cầu camera giám sát, cho phép giám sát 2-3 luồng camera đồng thời.
- Hội tụ ổn định: Loss giảm mượt mà, không dao động bất thường.

Hạn chế và thách thức:

- Class Imbalance: Fire:Smoke = 5.4:1 → Smoke Recall chỉ 66.7%, bỏ sót ~33%.
- Khói vô định hình: Không biên dạng cố định, dễ hòa lẫn mây/sương mù.
- mAP@0.5:0.95 hạn chế: 47.0% tổng, 37.8% Smoke — localization chưa chặt ở IoU cao.

CHƯƠNG 7: KẾT LUẬN

Mục tiêu	Kết quả	Đánh giá
mAP@0.5 ≥ 75% trên Test	77.4%	□ ĐẠT
Tốc độ ≥ 30 FPS	83 FPS	□ VƯỢT MỤC TIÊU
Phát hiện Fire & Smoke	Fire: 87.1%, Smoke: 67.7%	□ ĐẠT
Không overfitting	Test mAP > Val mAP	□ ĐẠT

Đóng góp chính:

- Xây dựng thành công mô hình YOLOv8s fine-tuned cho fire detection.
- Chứng minh tính khả thi sử dụng one-stage detector trên GPU phổ thông.
- Phân tích toàn diện điểm mạnh và hạn chế, đặc biệt thách thức phát hiện khói.
- Đề xuất cấu hình triển khai: conf=0.25-0.35 (cảnh báo sớm), conf=0.50-0.60 (dập lửa tự động).

CHƯƠNG 8: HƯỚNG PHÁT TRIỂN

8.1. Cải thiện hiệu năng

- Bổ sung 1,500-2,000 ảnh khói đa dạng để cân bằng dữ liệu.
- Tăng lên 70-80 epochs + Cosine Annealing LR → cải thiện 2-4% mAP.
- Thử nghiệm YOLOv8m/l, so sánh RT-DETR, YOLOv9, YOLOv10.

8.2. Mở rộng chức năng

- Video real-time: Camera IP/RTSP + tracking (DeepSORT, BoT-SORT).
- Semantic Segmentation: YOLOv8-seg phân đoạn chính xác vùng lửa/khói.
- Ước lượng mức độ nghiêm trọng: nhỏ / trung bình / lớn.

8.3. Edge Computing & IoT

- Xuất ONNX / TensorRT (Jetson) / TFLite (Android).
- Quantization INT8/FP16, Pruning, Knowledge Distillation.
- Push notification (Firebase), Sprinkler/Alarm relay, Dashboard web.
- Fusion camera hồng ngoại (thermal) + RGB + cảm biến nhiệt/khí.

CHƯƠNG 9: TÀI LIỆU THAM KHẢO

[1] Redmon, J. et al. (2016). "You Only Look Once: Unified, Real-Time Object Detection." CVPR. arXiv: 1506.02640

[2] Redmon, J. & Farhadi, A. (2017). "YOLO9000: Better, Faster, Stronger." CVPR. arXiv: 1612.08242

[3] Redmon, J. & Farhadi, A. (2018). "YOLOv3: An Incremental Improvement." arXiv: 1804.02767

[4] Bochkovskiy, A. et al. (2020). "YOLOv4: Optimal Speed and Accuracy of Object Detection." arXiv: 2004.10934

[5] Wang, C.-Y. et al. (2023). "YOLOv7: Trainable bag-of-freebies." CVPR. arXiv: 2207.02696

[6] Jocher, G. et al. (2023). "Ultralytics YOLOv8." GitHub: github.com/ultralytics/ultralytics

[7] Lin, T.-Y. et al. (2017). "Feature Pyramid Networks for Object Detection." CVPR. arXiv: 1612.03144

[8] Liu, S. et al. (2018). "Path Aggregation Network for Instance Segmentation." CVPR. arXiv: 1803.01534

[9] Zheng, Z. et al. (2020). "Distance-IoU Loss: Faster Learning for Bounding Box Regression." AAAI. arXiv: 1911.08287

[10] Lin, T.-Y. et al. (2017). "Focal Loss for Dense Object Detection." ICCV. arXiv: 1708.02002

[11] Li, P. & Zhao, W. (2020). "Image Fire Detection Algorithms Based on CNN." Case Studies in Thermal Eng.

[12] Saponara, S. et al. (2021). "Real-time video fire/smoke detection based on CNN." J. Real-Time Image Processing.

[13] Park, M. & Ko, B.C. (2020). "Two-Step Real-Time Night-Time Fire Detection." Sensors, 20(8), 2202.

[14] Abdusalomov, A.B. et al. (2023). "Improved Forest Fire Detection Based on Detectron2." Sensors, 23(3), 1512.

[15] Wang, D. et al. (2022). "Real-time Smoke and Fire Detection Based on Improved YOLOv5." IEEE ICET.

[16] Ultralytics YOLOv8 Documentation. https://docs.ultralytics.com/

[17] PyTorch Documentation. https://pytorch.org/docs/stable/

[18] Roboflow Universe — Fire and Smoke Datasets. https://universe.roboflow.com/

[19] NVIDIA CUDA Toolkit Documentation. https://docs.nvidia.com/cuda/

[20] Goodfellow, I. et al. (2016). Deep Learning. MIT Press.

[21] Géron, A. (2022). Hands-On Machine Learning (3rd Ed). O'Reilly Media.